

卒業論文 2021 年度 (令和 3 年)

「商取引ゲーム」をベースにした  
計算可能な複雑系としての社会契約

慶應義塾大学 環境情報学部  
宮元 眺

「商取引ゲーム」をベースにした  
計算可能な複雑系としての社会契約

社会契約とは、ある集団において、「各成員に合意された約束の履行を強制する力」を生じさせるプロセスである。この力がどのようにして生じるのかについては、交渉ゲーム理論や進化ゲーム理論を用いて研究されきた (Verbeek Bruno Christopher 2020)[1] が、大半の研究は、そのゲームにおける利得の分配を強制執行する力の存在が暗黙的に仮定されている。この強制執行力が集団の外部に存在することを仮定する場合、それは別の社会契約が成立していることを意味するため、社会契約を完全に説明することはできない。逆に、外部に強制執行力の存在を仮定しない場合、過去の歴史とそこから決定される社会指標を用いることで社会契約は成立するとされている (Binmore 2005)。しかしながら、その研究では内部的に強制執行力を生じさせるメカニズムについては還元主義的にしか説明されておらず、その強制執行力を生じさせる成員の振る舞いを明確に記述することはできなかった。本研究では、まず、外部の強制執行力として、「各成員から報告された約束の結果 (歴史) を記録し、それに基づいて各成員の評判 (社会指標) を決定するシステム」の存在を仮定し、そのシステムが各成員に合意された約束の履行を強制する条件について考えた。次に、そのシステムを、ビザンチン将軍問題の署名付きの解法を用い、各成員の振る舞いによって自己組織化された分散システムとして設計した。この分散システムを、マルチエージェントシミュレーションを用いて検証した結果、成員の構成によっては、一部の成員が想定されない振る舞いを行った場合でも、最終的に合意された約束が必ず履行される状況を作り出せることがわかった。これにより、外部の強制執行力が存在しない場合でも、成員の構成次第で社会契約が成立することを示せ、社会契約の成立に必要な歴史の定義や社会指標の計算方法、各成員の振る舞いを計算可能なレベルで明確に定義することができた。もし将来、コンピューターを用いた人々の社会契約が必要とされる時が来るならば、今回の研究がその実現に何らかの形で貢献することを願う。

キーワード:

1. 社会契約, 2. 複雑系, 3. マルチエージェントシミュレーション, 4.

慶應義塾大学 環境情報学部  
宮元 眺

# 目次

|        |                   |    |
|--------|-------------------|----|
| 第 1 章  | 序論                | 5  |
| 1.1    | 本研究の動機            | 5  |
| 1.2    | 本研究の貢献            | 6  |
| 1.3    | 本論の構成             | 6  |
| 第 2 章  | 背景                | 7  |
| 2.1    | 社会契約とは            | 7  |
| 2.2    | スタグハントゲーム         | 7  |
| 2.3    | 機能主義的なアプローチ       | 7  |
| 2.4    | 交渉理論を用いたアプローチ     | 8  |
| 2.5    | 進化ゲーム理論を用いたアプローチ  | 8  |
| 2.6    | 限定合理性             | 8  |
| 2.7    | 強制執行力             | 8  |
| 2.8    | 外部の強制執行力          | 8  |
| 2.9    | 複雑系               | 9  |
| 2.10   | 自己組織化             | 9  |
| 2.11   | ビザンチン将軍問題         | 9  |
| 2.12   | 署名されたメッセージによる解決策  | 9  |
| 2.12.1 | 仮定                | 10 |
| 2.12.2 | 関数 $choice(V)$    | 10 |
| 2.12.3 | アルゴリズム $SM(m)$    | 10 |
| 2.13   | マルチエージェントシミュレーション | 10 |
| 第 3 章  | 問題提起              | 11 |
| 3.1    | 本論の問題提起           | 11 |
| 3.2    | 問題解決の要件           | 11 |
| 3.2.1  | 歴史を定義する           | 11 |
| 3.2.2  | 社会指標の決定方法を定義する    | 11 |
| 3.2.3  | 成員の振る舞いとして記述できる   | 11 |
| 第 4 章  | 仮説と検証方法           | 12 |
| 4.1    | 本論の仮説             | 12 |
| 4.2    | 検証方法              | 12 |
| 第 5 章  | 約束・評判ゲーム          | 14 |
| 5.1    | 補題 1              | 14 |
| 5.2    | 検証方法              | 14 |
| 5.3    | 評判システム            | 14 |

---

|            |                                    |           |
|------------|------------------------------------|-----------|
| 5.4        | 約束・評判ゲーム                           | 14        |
| 5.4.1      | 展開型ゲーム                             | 15        |
| 5.4.2      | 各プレイヤーの戦略                          | 16        |
| 5.4.3      | 非協力戦略型ゲーム                          | 16        |
| 5.5        | 補題1の検証                             | 16        |
| 5.5.1      | 不正が防止される条件                         | 16        |
| 5.5.2      | 命題                                 | 17        |
| 5.5.3      | 証明                                 | 17        |
| <b>第6章</b> | <b>倫理ある商取引ゲーム</b>                  | <b>20</b> |
| 6.1        | 本章における問題提起                         | 20        |
| 6.2        | 本章の仮説                              | 20        |
| 6.3        | 提案手法                               | 20        |
| 6.3.1      | 倫理ある商取引ゲーム                         | 20        |
| 6.3.2      | 誠実な戦略をとった割合と成功が報告される割合の関係          | 21        |
| 6.4        | 「倫理ある商取引ゲーム」において不正が防止される条件         | 21        |
| 6.4.1      | 不正が抑制される戦略組と期待利得の不等式               | 21        |
| 6.4.2      | <i>seller</i> と <i>buyer</i> の期待利得 | 21        |
| 6.4.3      | <i>seller</i> が誠実な戦略をとる条件          | 22        |
| 6.4.4      | <i>buyer</i> が誠実な戦略をとる条件           | 22        |
| 6.4.5      | 信頼度 $p^{player}$                   | 22        |
| 6.4.6      | 最低信頼度 $T^{player}$                 | 23        |
| 6.4.7      | 最低信頼度を用いた条件                        | 23        |
| 6.5        | 実験方法                               | 23        |
| 6.5.1      | エージェントの種類                          | 23        |
| 6.5.2      | 試行                                 | 24        |
| 6.6        | 「商取引システム」の詳細                       | 25        |
| 6.6.1      | ReputationWeight                   | 25        |
| 6.6.2      | 「成功」が報告された場合の通貨保有量の変化              | 25        |
| 6.6.3      | EscrowCost                         | 25        |
| 6.6.4      | EscrowCost の負担比率                   | 25        |
| 6.6.5      | EscrowCost の分配                     | 26        |
| 6.7        | 評価                                 | 26        |
| 6.8        | 結論                                 | 26        |
| 6.8.1      | 非協力戦略型ゲーム                          | 28        |
| <b>第7章</b> | <b>複雑系としての社会契約</b>                 | <b>29</b> |
| 7.1        | 本章の問題提起                            | 29        |
| 7.2        | 本章の仮説                              | 29        |
| 7.3        | 提案手法                               | 29        |
| 7.3.1      | 成員の振る舞い                            | 29        |
| 7.3.2      | 時刻 $t$ における成員の振る舞い                 | 30        |
| 7.4        | 実験方法                               | 30        |
| 7.4.1      | 実験用の商取引契約                          | 30        |

|              |                     |           |
|--------------|---------------------|-----------|
| 7.4.2        | step6 の検証 . . . . . | 31        |
| 7.4.3        | エージェントの種類 . . . . . | 31        |
| 7.4.4        | 試行 . . . . .        | 31        |
| 7.5          | 評価 . . . . .        | 32        |
| <b>第 8 章</b> | <b>結論</b>           | <b>34</b> |
| 8.1          | 本論のまとめ . . . . .    | 34        |
| 8.2          | 本論の課題 . . . . .     | 34        |
| 8.3          | 今後の研究 . . . . .     | 34        |

# 第1章 序論

## 1.1 本研究の動機

社会契約とは、ある集団において、その成員達に合意された約束を遵守させる強制力が生じるプロセスである。中世において、社会契約はホッブズやロック、ルソーによって議論され、なぜ国家において国民が法に従うのかを論理的に説明しようと試みることで王権神授説を否定する主張として注目された。現代においては、ロールズやハースニーが中世の社会契約論の一般化を試み、その社会契約のプロセスの果に導きだされる公正な正義とはどういったものかを議論した。それ以降、社会契約は倫理や正義論といった概念と結びつけて考えられることが多くなった。

このように社会契約が研究される意義は、社会の変化とともに移り変わっている。今後も社会の様々な変化に伴って社会契約の研究意義は変化していくだろう。その中でも、インターネットの普及がもたらす社会の変化は、社会契約の研究に新たな意義を与えていると考えている。

2020年のGSMA[2]の調査では、モバイル回線のユニークな契約者数は5.8億人に登り、実に世界人口の70%がモバイル回線を所有していることが示唆されている。インターネットユーザーが全世界で増加する一方、Google[3]やFacebook[4]のように全世界にユーザーをかかえるまで成長するサービスが現れ、そうしたサービスの運営会社も多国籍企業として多数の国に支社を置くようになっている。こうした企業のガバナンスは、もはや一国の法にのみ依存するものではなくなっている。

また、誰にも送金を止めさせないことを目的としたBitcoin[5]の登場を皮切りに、ブロックチェーンを用いた様々な分散型台帳技術を用いたサービスが出現している。こうしたシステムはP2Pと呼ばれる通信技術を用いており、世界中のコンピューターがそのノードとしてシステムの運用を担っていたため、単一の国家がそのサービスを規制するのは極めて困難である。

こうしたインターネット上のサービスのグローバル化や新技術の登場により、インターネットを国家という枠組みを超越した社会インフラへ進化していると言えるだろう。こうした進化の先に、「地球規模OS」[6]のような地球規模で資源を抽象化して共有可能にするシステムが当たり前存在する未来が到来すると期待される。

そうした未来の実現に向かって必ず衝突する問題は、国家を超越したインターネット上に存在するサービスの正当性をどのように保証するかという問題である。先に述べたとおり、一国の法による拘束力では、サービスの運営母体を規制することは困難である。Bitcoinブロックチェーンにおいては、Proof of Workと呼ばれる技術によって、確率的にその正当性を保証しようとしているが、そのためだけに世界中で大量の計算リソースが消費され続けている。これが国家を超越した社会インフラを維持するベストな方法だとは安易に納得したくない。

我々はこの問題を解決する糸口は社会契約の理論研究にあると考えている。かつて中世の社会契約論者が説明したように、国家の法が国民の社会契約によって成立するのであれば、国家を超越したインターネット上の法はインターネットユーザーによる社会契約によって成立するのではないだろうか。仮に国家を超越したインターネット上の法が成立するのならば、それによってサービスの正当性を保証すればよい。こうしたアイディアが本研究のモチベーションである。

## 1.2 本研究の貢献

本研究では、インターネットユーザーの集団を想定して社会契約の理論を再構築する。当然のごとく、彼らはコンピュータを用いてインターネットでやり取りをするため、社会契約のモデルは (コンピュータで) 計算可能なレベルまで抽象化する。それにあたって課題となるのは、強制執行力である。これまでの研究において、この強制執行力の存在は暗黙的に存在が仮定されているか、外部の強制執行力としてその存在が仮定されているかのいずれかであった。Binmore の研究では、この外部の強制執行力が存在しない場合についても社会契約が成立することが示されている [7] が、その説明は還元主義的なものであり、具体的に成員のどのような振る舞いによってそれがなし得るのか記述することはできなかった。本研究では、この内部的に強制執行力が生じるメカニズムを成員の振る舞いとして具体的に記述を可能にする。これにより、社会契約の全体を計算可能なレベルでのモデリングすることが可能となる。また、コンピュータシミュレーションを用いて、そのモデルを検証することで、ある集団における成員の性質と社会契約の成立の関係性を明らかにする。

## 1.3 本論の構成

## 第2章 背景

### 2.1 社会契約とは

社会契約とは、ある集団において、「各成員に合意された約束の履行を強制する力」を生じさせるプロセスである。中世において、社会契約はホブズやロック、ルソーによって議論され、なぜ国家において国民が法に従うのかを論理的に説明しようと試みることで王権神授説を否定する主張として注目された。現代においては、ロールズやハースニーが中世の社会契約論の一般化を試み、その社会契約のプロセスの果に導きだされる公正な正義とはどういったものかを議論した。それ以降、社会契約は倫理や正義論といった概念とともに、ゲーム理論を用いて分析されるようになり、機能主義、交渉理論、進化ゲーム理論の3つのアプローチがなされている。[1]

### 2.2 スタグハントゲーム

|                            |    | <i>hunter</i> <sub>2</sub> |       |
|----------------------------|----|----------------------------|-------|
|                            |    | 鹿                          | 野兎    |
| <i>hunter</i> <sub>1</sub> | 鹿  | (2,2)                      | (0,1) |
|                            | 野兎 | (1,0)                      | (1,1) |

表 2.1: スタグハントゲームの利得表

スタグハントゲームとは、ルソーの「人類不平等起源論」[8]に登場する「鹿狩りの寓話」をモデリングした非協力戦略型ゲームである。[9] 二人のハンターが協力して鹿を狩るか、相手を裏切って野兎を狩るかを選択するが、鹿は2人で協力しなければ狩ることができず、1人だけで狩ろうとすると何も得ることができない。このゲームは代表的な囚人のジレンマゲームであり、非協力解(両者が野兎を狩る戦略をとる解)がナッシュ均衡になることが知られている。こうした囚人のジレンマゲームは社会契約が成立する原理を説明する鍵だと考えられている。[9]

### 2.3 機能主義的なアプローチ

Edna Ullmann-Margalit は、同様の囚人のジレンマゲームを持ち出し、道徳的な規範がプレイヤーが、自己利得の最大化のために非協力解に陥ることを妨げていることを説明した。[10] Mackie の研究においても、同様に、道徳の機能は合理性の失敗を防ぐことにあるとされる。[11] しかしながら、こうしたアプローチは道徳的な規範の機能を説明する一方で、なぜプレイヤーがその規範に従うのかについては説明がなされていない。



## 2.4 交渉理論を用いたアプローチ

交渉ゲーム理論を用いたアプローチとしては、Harsanyi 1955[12] や Rawls 1971[13]、Gauthier 1986[?] などが挙げられる。彼らは道徳的な規範に基づいた解も合理的な戦略決定によって生じていると考え、交渉ゲーム理論を用いて、どのような協力解が選択されるのかを説明しようとした。しかしながら、こうしたアプローチは、選択可能な社会契約の集合から、それぞれの交渉解の要件に沿った社会契約を選択されるのかを解明しようとするものであり、具体的にどういったプロセスでその解に至るのかはわからない。

## 2.5 進化ゲーム理論を用いたアプローチ

進化ゲーム理論を用いたアプローチは、道徳的な規範がどのようなプロセスで出現し維持されるのかを解明しようとしている。複数の研究で [14][15][16][17] 限定合理的なエージェントの間でも道徳的な規範が出現することが示されており、こうした規範は相互作用の繰り返しの中で主体の行動の意図しない副作用として生じるものだと考察されている。それゆえ、安定した規範が必ずしもパレート効率だとは限らず、交渉ゲーム理論を用いたアプローチが仮定しているような効率性と道徳性の関係は存在しないといえる。[1]

## 2.6 限定合理性

進化ゲーム理論においては、限定合理性が仮定された上で議論が進められる。限定合理性とは、意思決定主体が認知能力の限界によって限定された合理性しか発揮することができない性質である。[18] ゲーム理論においては、「自己利得を最大化する合理的なプレイヤー」という仮定の上では説明が困難だった実社会の協力的な行動を解明するために用いられている。[19] 最後通牒ゲームの実験は、その最もたる例であり、実社会のプレイヤーは相手よりも少ない取り分を提示されると自身の利得が 0 になるにも関わらず報復的な戦略を選んでいく。[20]

## 2.7 強制執行力

これまでの社会契約の研究では、強制執行力と呼ばれる「合意された利得の分配を強制的に執り行っている力」の存在が暗黙的に仮定されている。先に紹介したスタグハントゲームでいうところの、二人で協力して鹿を狩った場合にその鹿を二人で分け合うという取り決めを守らせている力である。Rawls の「自然の義務」[13] や Harsanyi の「道徳的コミットメント」[12] などがこれに当たるとされる。[7]

## 2.8 外部の強制執行力

強制執行力のうち、集団の外部の機関によってもたらされる力を外部の強制執行力と呼ぶ。外部の強制執行力が存在する場合、そこには別の社会契約が存在していることになる。Binmore は交渉ゲーム理論と進化ゲーム理論を用いてこの外部の強制執行力が存在する場合と存在しない場合の社会契約について分析し、下記のような結論を導き出した。[7]

外部の強制執行力が存在する場合、合理的なプレイヤーが合意する可能性のある契約はどれも無限回の繰り返しゲームの均衡結果となり得る。

外部の強制執行力が存在しない場合、過去の歴史が決定する社会指標を利用した平等主義的 (ロールズの) 交渉解によって解決される。

## 2.9 複雑系

複雑系とは相互に作用し合う可能性のある複数の要素によって構成されるシステムである。複雑系において、システム全体としての振る舞いは各構成要素の振る舞いによって決定論的に決まるが、その関係性が非線形的であり些細なパラメーターの変化で結果が大きく異なってしまうため、個々の振る舞いから全体の挙動を予測することは困難である。還元主義的なアプローチはシステム全体の振る舞いをシステムを分解することで理解しようとするのに対し、複雑系のアプローチは構成要素の振る舞いの変化とそれに伴うシステム全体の振る舞いの変化を観察することで理解しようとする。

本論では、社会契約を成立させようとする集団を、成員によって構成される複雑系として捉え、彼らの振る舞いの変化が社会契約の成立にどのように影響をもたらすのかを解析する。

## 2.10 自己組織化

自己組織化とは、複雑系において、システム全体を俯瞰できない構成要素の振る舞いによって、全体として秩序だった振る舞いがなされる現象である。2.5 節で述べたような道徳的な規範が生じる現象は、まさにこの自己組織化の例である。本論では、強制執行力を社会契約の複雑系の中で自己組織化された現象として設計する。設計にあたっては次節で紹介するビザンチン将軍問題とその解決策を用いる。

## 2.11 ビザンチン将軍問題

ビザンチン将軍問題とは、分散システムの構成し相互に通信しあうノード群において、それぞれのノードが本体の故障または故意によって偽の情報を伝達したり何も情報を伝達しない可能性がある場合に、全ての正常なノードが単一の値を共有することができるかを問う問題である。[21] 名称の通り、ビザンチン帝国の将軍たちが司令を共有する問題として記述されており、具体的には次のようなものである。

ビザンチン帝国の将軍たちが 1 つの都市を包囲しており、「攻撃」か「撤退」か合意したいと考えている。一部の将軍たちは「攻撃」を提案し、他は「撤退」を提案するかもしれないが、一部の将軍だけで攻撃すると失敗してしまう。将軍たちは、それぞれ離れた場所にいるため、メッセージを相互に送って自分の司令を伝えようとするが、全ての将軍が誠実とは限らず、中には裏切り者もいて意見を分断させようとするかもしれない。ここで自身の司令（「攻撃」か「撤退」）を伝えようとしている将軍を司令官、他の全ての将軍を副官としたとき、IC1 と IC2 を同時に達成する方法はあるだろうか。

IC1. すべての誠実な副官は同じ司令に従う。

IC2. 司令官が誠実な場合、全ての誠実な副官は彼の送った司令に従う。

## 2.12 署名されたメッセージによる解決策

この問題にはいくつかの解決策が存在しているが、ここでは問題が提起されたの論文の中で取り上げられている「署名されたメッセージによる解決策」を紹介する。それによれば、裏切り者の人数を  $m$  としたとき、A1~A5 の 5 つの仮定の上で、 $m+1$  人以上の将軍がいれば下記のアルゴリズムで IC1 と IC2 を同時に満たせることが証明されている。将軍の人数を  $n$  としたとき、 $i \in \{1, \dots, n-1\}$  であり、 $lieutenant_i$  は  $i$  番目の将軍を指す。任意の値  $w$  に対して、 $w : i$  は  $i$  番目の将軍によって署名がついた値である。 $w : 0$  の場合は司令官の将軍の署名がついた値を指す。

### 2.12.1 仮定

- A1 送信されたすべてのメッセージは正しく到達する
- A2 メッセージの受信者は誰が送信したのかわかる
- A3 メッセージが届かないことを検知できる
- A4 誠実な将軍の署名は偽造できず、署名されたメッセージの内容が変更されても、それを検知することができる。
- A5 誰でも将軍の署名の信憑性を検証することができる。

### 2.12.2 関数 $choice(V)$

関数  $choice(V)$  は集合  $V$  を引数にとって司令 (「攻撃」か「撤退」) を返す関数である。

1. もし集合に単一の司令  $v$  しか存在しなければ、 $choice(V) = v$  とする。
2.  $choice(\emptyset) = RETREAT$  とする。 $\emptyset$  は空集合。
3. もとの論文で抜けてるけど、 $V$  が 2 つあるときは  $RETREAT$ ?

### 2.12.3 アルゴリズム $SM(m)$

1.  $V_i = \emptyset$  として初期化する。 $(\emptyset$  は空集合)
2. 司令官は彼の値を全ての副官に署名して送る。
3. 各  $i$  について、
  - (a) もし  $lieutenant_i$  が  $v : 0$  という形式のメッセージを受け取り、まだ何の命令も受けていない場合は、
    - i.  $lieutenant_i$  は  $V_i$  を  $v$  にする。
    - ii.  $lieutenant_i$  は他のすべての中尉にメッセージ  $v : 0 : i$  を送ります。
  - (b) もし  $lieutenant_i$  が  $v : 0 : j_1 : \dots : j_k$  という形式のメッセージを受け取り、 $v$  が集合  $V_i$  に入っていない場合は
    - i.  $lieutenant_i$  は  $v$  を  $V_i$  に追加する。
    - ii. もし  $k < m$  であれば、 $lieutenant_i$  は  $j_1, \dots, j_k$  以外のすべての副官に  $v : 0 : j_1 : \dots : j_k : i$  というメッセージを送る。
4. 各  $i$  について。  $lieutenant_i$  がこれ以上メッセージを受け取らない場合、 $lieutenant_i$  は命令  $choice(V_i)$  に従う。

## 2.13 マルチエージェントシミュレーション

マルチエージェントシミュレーションとは、与えられた方策に従って振る舞う複数のエージェントとそのエージェント達を内包する環境を定義し、計算機によって、それらのエージェントの振る舞いをシミュレーションすることで、エージェント達の振る舞いによってもたらされる相互作用を観察する手法である。本論では、分散システムとして設計されたシステムの検証のために用いる。

## 第3章 問題提起

### 3.1 本論の問題提起

これまでのゲーム理論を用いた社会契約の研究では、どのようなプロセスで道徳的な規範が生じ維持され、社会契約が成立するかについて議論されていたが、成員のどのような振る舞いによって、そのプロセスが進行しているのか記述することができなかった。その最もたる障害は強制執行力の存在である。先にも述べたとおり、強制執行力が集団の外部に存在する場合、それは別の社会契約の成立を意味する。それ故、こうした仮定の上で社会契約の説明を試みても問題が堂々巡りに陥ってしまい、完全な社会契約のモデルを構築には至れない。一方、外部の強制執行力が存在しない場合については、社会の過去の歴史が決定する社会指標を利用することで社会契約が成立するとされている (Binmore 2005[7]) が、この研究は還元主義的なアプローチをとっており、社会契約に必要な歴史の定義や、社会指標の計算方法、成員達の具体的な振る舞いを記述することは困難である。

本研究では、改めて外部の強制執行力が存在しない場合について、「合意された約束の履行を成員達に強制する力」を生じさせることが可能なのかという問いに取り組む。その過程で、どのように歴史を決定し、そこからどのように社会指標を導き出し、成員達がそれに基づいてどのように振る舞えば社会契約が成立するのかを計算可能なレベルで明確にする。

### 3.2 問題解決の要件

先の問題が解決されるためには、成員達が合意された約束を遵守する状態を作り出せていることを示す他に、下記の3つの要件が満たされている必要がある。

#### 3.2.1 歴史を定義する

第1に、社会契約の成立のために必要な歴史とはいかなるものかを定義する必要がある。これは社会指標を計算するために各成員が記録すべき過去のある集団の何らかの状態である。

#### 3.2.2 社会指標の決定方法を定義する

第2に、歴史から社会指標を計算する方法を定義する必要がある。合意された約束が遵守されるようにするため、この社会指標は約束を履行する成員の社会指標が上がり、約束を保護にする成員の社会指標が下がるように設計する必要がある。

#### 3.2.3 成員の振る舞いとして記述できる

第3に、各成員の振る舞いによってのみ、歴史が共有されて各成員の社会指標を計算でき、その振る舞いを記述可能である必要がある。これは外部の強制執行力が存在しない場合、あらゆる歴史も計算された社会指標も、その正当性を保証した状態で外部に記録共有することができないためである。

## 第4章 仮説と検証方法

### 4.1 本論の仮説

我々は、先の問について、外部の強制執行力が存在しない場合でも、成員の振る舞いによって強制執行力を自己組織化することが可能であり、集団を構成する成員達の性質によっては、「成員達に合意された約束の履行を強制させる力」を生じさせることができると考えている。本論では、この仮説を示すために下記の3つ仮説を補題として扱い順に検証する。

**補題1** 成員の行動を観察できない外部の強制執行力が存在すると仮定した上で、完全に合理的な成員達に合意された約束を履行させるインセンティブ設計は不可能である。

**補題2** 成員の行動を観察できない外部の強制執行力が存在すると仮定した上で、集団を構成する成員達の性質によっては、成員達に合意された約束を履行させるインセンティブ設計が可能である。

**補題3** 外部の強制執行力が存在しない場合でも、成員の振る舞いによって強制執行力を自己組織化させることが可能である。

### 4.2 検証方法

本論では、補題1～3を順に検証することで、仮説を示す。その手順について概要をここで述べる。

まず、成員の行動を観察できない外部の強制執行力を「評判システム」と定義した上で議論を進め、補題1を示す。「評判システム」とは報告された約束の結果に基づいて各成員の評判スコアを決定するシステムである。また、そのシステムを用いた任意の約束を結ぶ2人の「約束・評判ゲーム」について考える。これは一方 (*promisor*) が約諾し、もう一方 (*reporter*) がその約束の結果 (「成功」か「失敗」) を「評判システム」に報告する非協力戦略型ゲームである。このゲームに参加するプレイヤーが完全に合理的な場合、両者がとりうる各戦略の利得を比較することで、彼らの約束が真に成功する (*promisor* が約束を履行し、*reporter* が「成功」を報告する) 条件を導く。全ての成員が完全に合理的な場合、「評判システム」が報告された約束の結果から、その条件を満たす評判スコアを決定することができないことを示す。

次に、補題1を踏まえて、全ての成員が約束を反故にされた場合に「失敗」を報告する「倫理ある約束・評判ゲーム」について考えることで補題2を示す。そして、補題1と同様に、成員がとりうる各戦略の利得を比較することで、この「倫理ある約束・評判ゲーム」において、彼らの約束が真に成功する条件を導く。「倫理ある約束・評判ゲーム」においては、「評判システム」が報告された約束の結果 (「成功」か「失敗」) から、その条件を満たす評判スコアを決定することができることを示す。その条件を満たす「評判システム」の詳細を定義し、戦略の限定されない通常の「約束・評判ゲーム」において、定義した評判システムが機能するかマルチエージェントシミュレーションを用いて検証する。その結果から、集団を構成する成員達の性質によっては、全ての約束が成功する状態に至ることを示す。

最後に、各成員が「評判システム」を所有している場合について考えることで、補題3を示す。ビザンチン將軍問題の署名付きの解決策を用いて、「評判システム」を各成員の振る舞いによる分散システムとして設計可能であることを示す。補題2の条件に基づいて実装された「評判システム」を同様に各成員の振る舞

いとして定義し、マルチエージェントシミュレーションを用いて検証する。その結果から、外部の強制執行力が存在しない場合でも、成員の振る舞いによって強制執行力を自己組織化させることが可能であり、集団を構成する成員達の性質によっては、全ての約束が成功する状態に至ることがわかる。

また、補題 3 の実験結果から、「評判システム」が成員達の振る舞いによって自己組織化された分散システムとして機能し、集団を構成する成員達の性質によっては、「約束-評判ゲーム」で全ての約束が成功する状態に至ることが示される。これにより、先の仮説が立証され、社会契約の成立に必要な歴史の定義や社会指標の決定方法、具体的な成員の振る舞い、その振る舞いに従う成員の人数と社会契約の成立の関係性を明らかにすることができる。

## 第5章 約束・評判ゲーム

本章では、4.1 節で定義した補題 1 を検証する。

### 5.1 補題 1

成員の行動を観察できない外部の強制執行力が存在すると仮定した上で、完全に合理的な成員達に合意された約束を履行させるインセンティブ設計は不可能である。

### 5.2 検証方法

成員の行動を観察できない外部の強制執行力として「評判システム」(5.3 節) の存在を仮定し、2 人の成員が、そのシステムを用いて約束を交わす「約束・評判ゲーム」(5.4) について考える。このとき、各成員が約束によって生じる価値と「評判スコア」の合計を最大化しようとする場合、約束が履行されるような「評判スコア」を「評判システム」から決定できないことを示す。

### 5.3 評判システム

「評判システム」とは、初期の各成員の「評判スコア」と報告された約束の記録に基づいて、各成員の「評判スコア」を決定するシステムである。約束の記録とは、約諾者が約束を履行したかについての情報であり、約諾者、報告者、結果(「成功」か「失敗」)からなる。このシステムから成員の行動を観察することはできないため、約諾者が真に約束を履行したか否かと報告された結果が同じとは限らない。このシステムは、「約束・評判ゲーム」(5.4 節) において、強制執行力としての役割を果たす。

### 5.4 約束・評判ゲーム

「約束・評判ゲーム」とは、約諾者 (*promisor*) と報告者 (*reporter*) の 2 人によって行われるゲームである。約諾者は 2 者間で合意された約束を履行する、もしくは反故にする。それに対して報告者は約束の結果(「成功」か「失敗」)を決定し、約束の記録を「評判システム」に報告する。

**step1** *promisor* は合意された約束を履行する、もしくは反故にする。

**step2** *reporter* は「成功」か「失敗」を「評判システム」に報告する。

### 5.4.1 展開型ゲーム

これは図 5.1 のゲームの木のような展開型ゲームとして表せる。各変数については下記の通りである。

**step1** で *promisor* が約束を履行するか反故にするかと、**step2** で *reporter* が「成功」を報告するか「失敗」を報告するかで 4 つの結果がある。また、「評判システム」からは *promisor* と *reporter* の行動を観察できないため、**step2** での *reporter* の報告に基づいて *promisor* と *reporter* の「評判スコア」が決定しなければならない。それ故、①と③、②と④はそれぞれ  $c_k$  ( $k$  は任意) を除いて同じ利得でなくてはならない。

#### 各変数の定義

$c_{p1}$  … 約束が履行された場合の *promisor* の「評判スコア」の変化量以外の効用

$c_{p2}$  … 約束が反故にされた場合の *promisor* の「評判スコア」の変化量以外の効用

$c_{r1}$  … 約束が履行された場合の *reporter* の「評判スコア」の変化量以外の効用

$c_{r2}$  … 約束が反故にされた場合の *reporter* の「評判スコア」の変化量以外の効用

$r_{ps}$  … 「成功」が報告された場合の *promisor* の「評判スコア」の変化量

$r_{pf}$  … 「失敗」が報告された場合の *promisor* の「評判スコア」の変化量

$r_{rs}$  … 「成功」が報告された場合の *reporter* の「評判スコア」の変化量

$r_{rf}$  … 「失敗」が報告された場合の *reporter* の「評判スコア」の変化量

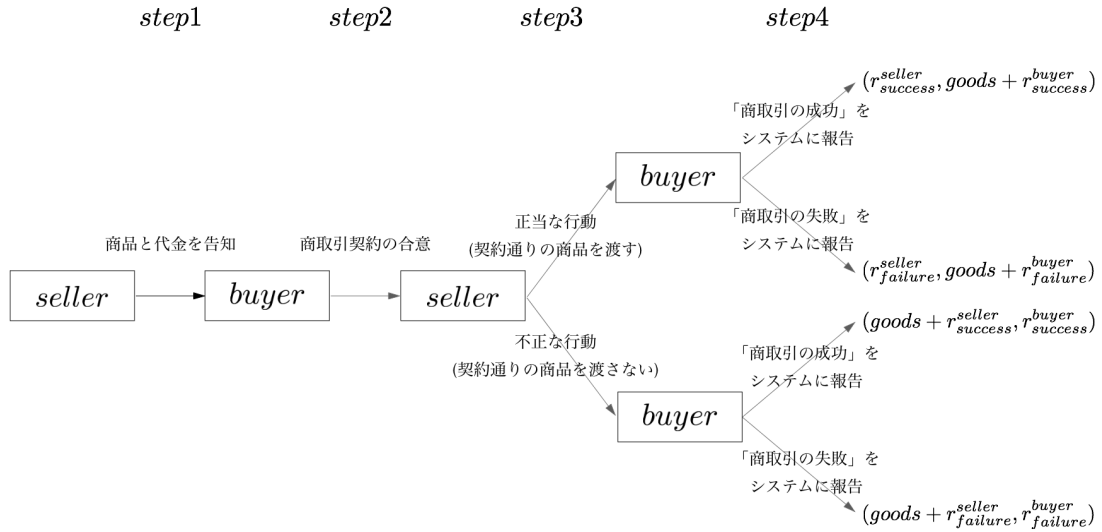


図 5.1: 「約束・評判ゲーム」のゲーム木



### 5.4.2 各プレイヤーの戦略

この展開型ゲームにおける *promisor* と *reporter* の行動は、下記のような戦略として表せる。

*promisor* の戦略

$s_{p1}$  … 約束を履行する

$s_{p2}$  … 約束を反故にする

*reporter* の戦略

$s_{r1}$  … *promisor* が約束を履行した場合は「成功」、反故にした場合は「失敗」を報告する

$s_{r2}$  … *promisor* が約束を履行した場合は「成功」、反故にした場合は「成功」を報告する

$s_{r3}$  … *promisor* が約束を履行した場合は「失敗」、反故にした場合は「失敗」を報告する

$s_{r4}$  … *promisor* が約束を履行した場合は「失敗」、反故にした場合は「成功」を報告する

### 5.4.3 非協力戦略型ゲーム

これらの戦略を用いて、先に述べた展開型ゲームは表 5.1 のような非協力戦略型ゲームとして書き換えられる。

|                 |          | <i>Reporter</i>                           |   |   |   |
|-----------------|----------|---|---|---|---|
|                 |          | $s_{r1}$                                  | $s_{r2}$                                  | $s_{r3}$                                  | $s_{r4}$                                  |
| <i>Promisor</i> | $s_{p1}$ | $(c_{p1} + r_{ps},$<br>$c_{r1} + r_{rs})$ | $(c_{p1} + r_{ps},$<br>$c_{r1} + r_{rs})$ | $(c_{p1} + r_{pf},$<br>$c_{r1} + r_{rf})$ | $(c_{p1} + r_{pf},$<br>$c_{r1} + r_{rf})$ |
|                 | $s_{p2}$ | $(c_{p2} + r_{pf},$<br>$c_{r2} + r_{rf})$ | $(c_{p2} + r_{ps},$<br>$c_{r2} + r_{rs})$ | $(c_{p2} + r_{pf},$<br>$c_{r2} + r_{rf})$ | $(c_{p2} + r_{ps},$<br>$c_{r2} + r_{rs})$ |

表 5.1: 「約束・評判ゲーム」の利得票表

## 5.5 補題 1 の検証

### 5.5.1 不正が防止される条件

表 5.1 より、「約束・評判ゲーム」において、約束が履行されるためには、*promisor* と *reporter* のとる戦略組が  $(s_{p1}, s_{r1})$  もしくは  $(s_{p1}, s_{r2})$  のいずれかになる必要がある。各プレイヤーが戦略  $s$  をとったときの利得を  $R$  とし、その期待値を  $E(R|s)$  とする。全てのプレイヤーが完全に合理的な場合、 $(s_{p1}, s_{r1})$  か  $(s_{p1}, s_{r2})$  のいずれかの戦略組に帰着させるためには、

$$\text{条件① } E(R|s_{p1}) > E(R|s_{p2}) \text{ かつ } E(R|s_{r1}) > \max\{E(R|s_{r2}), E(R|s_{r3}), E(R|s_{r4})\}$$

$$\text{条件② } E(R|s_{p1}) > E(R|s_{p2}) \text{ かつ } E(R|s_{r2}) > \max\{E(R|s_{r1}), E(R|s_{r3}), E(R|s_{r4})\}$$

のいずれかを満たす  $(r_{ps}, r_{pf}, r_{rs}, r_{rf})$  の組を「評判システム」から決定できる必要がある。本章ではこれが不可能であることを示す。

### 5.5.2 命題

条件①か条件②のいずれかを満たす  $(r_{ps}, r_{pf}, r_{rs}, r_{rf})$  の組を「評判システム」から決定することはできない。

### 5.5.3 証明

各プレイヤーが戦略  $s_k$  をとる確率を  $p_k$  とする。

$$\begin{aligned} 0 &\leq p_k \leq 1 \\ p_{p1} + p_{p2} &= 1 \\ p_{r1} + p_{r2} + p_{r3} + p_{r4} &= 1 \end{aligned} \tag{5.1}$$

各戦略の期待利得

*promisor* と *reporter* の各戦略の期待利得は次のように表せる。

$$\begin{aligned} E(R|s_{p1}) &= p_{r1}(c_{p1} + r_{ps}) + p_{r2}(c_{p1} + r_{ps}) + p_{r3}(c_{p1} + r_{pf}) + p_{r4}(c_{p1} + r_{pf}) \\ &= c_{p1} + p_{r1}r_{ps} + p_{r2}r_{ps} + p_{r3}r_{pf} + p_{r4}r_{pf} \because (5.1) \end{aligned} \tag{5.2}$$

$$\begin{aligned} E(R|s_{p2}) &= p_{r1}(c_{p2} + r_{pf}) + p_{r2}(c_{p2} + r_{ps}) + p_{r3}(c_{p2} + r_{pf}) + p_{r4}(c_{p2} + r_{ps}) \\ &= c_{p2} + p_{r1}r_{pf} + p_{r2}r_{ps} + p_{r3}r_{pf} + p_{r4}r_{ps} \because (5.1) \end{aligned} \tag{5.3}$$

$$E(R|s_{r1}) = p_{p1}(c_{r1} + r_{rs}) + p_{p2}(c_{r2} + r_{rf}) \tag{5.4}$$

$$E(R|s_{r2}) = p_{p1}(c_{r1} + r_{rs}) + p_{p2}(c_{r2} + r_{rs}) \tag{5.5}$$

$$E(R|s_{r3}) = p_{p1}(c_{r1} + r_{rf}) + p_{p2}(c_{r2} + r_{rf}) \tag{5.6}$$

$$E(R|s_{r4}) = p_{p1}(c_{r1} + r_{rf}) + p_{p2}(c_{r2} + r_{rs})$$

条件①が成り立たないことの証明

条件①が成り立たないことを示すために、その必要条件である下記の 2 つの条件について考える。

$$E(R|s_{r1}) > E(R|s_{r2}) \tag{5.7}$$

$$E(R|s_{r1}) > E(R|s_{r3}) \tag{5.8}$$

(5.7) を満たすためには、

$$\begin{aligned} E(R|s_{r1}) &> E(R|s_{r2}) \\ \therefore p_{p1}(c_{r1} + r_{rs}) + p_{p2}(c_{r2} + r_{rf}) &> p_{p1}(c_{r1} + r_{rs}) + p_{p2}(c_{r2} + r_{rs}) \because (5.4)(5.5) \\ \therefore p_{p2}r_{rf} - p_{p2}r_{rs} &> 0 \\ \therefore p_{p2}(r_{rf} - r_{rs}) &> 0 \end{aligned}$$

つまり、

$$p_{p2} > 0$$

かつ

$$0 > r_{rs} - r_{rf} \quad (5.9)$$

を満たす必要がある。

(5.8) を満たすためには、

$$\begin{aligned} E(R|s_{r1}) &> E(R|s_{r3}) \\ \therefore p_{p1}(c_{r1} + r_{rs}) + p_{p2}(c_{r2} + r_{rf}) &> c_{p2} + p_{r1}r_{pf} + p_{r2}r_{ps} + p_{r3}r_{pf} + p_{r4}r_{ps} \because (5.4)(5.6) \\ \therefore p_{p1}r_{rs} + p_{p2}r_{rf} &> p_{p1}r_{rf} + p_{p2}r_{rf} \\ \therefore p_{p1}(r_{rs} - r_{rf}) &> 0 \end{aligned}$$

つまり、

$$p_{p1} > 0$$

かつ

$$r_{rs} - r_{rf} > 0 \quad (5.10)$$

を満たす必要がある。

ここで (5.9) と (5.10) を同時に満たすことはできないため、条件①は成り立たない。

条件②が成り立たないことの証明

次に、条件②の必要条件である

$$E(R|s_{p1}) > E(R|s_{p2}) \quad (5.11)$$

について考える。

(5.11) を満たすためには、

$$\begin{aligned} E(R|s_{p1}) &> E(R|s_{p2}) \\ \therefore c_{p1} + p_{r1}r_{ps} + p_{r2}r_{ps} + p_{r3}r_{pf} + p_{r4}r_{pf} &> c_{p2} + p_{r1}r_{pf} + p_{r2}r_{ps} + p_{r3}r_{pf} + p_{r4}r_{ps} \\ \therefore c_{p1} + p_{r1}r_{ps} + p_{r4}r_{pf} &> c_{p2} + p_{r1}r_{pf} + p_{r4}r_{ps} \\ \therefore c_{p1} - c_{p2} + p_{r1}r_{ps} + p_{r4}r_{pf} + p_{r1}r_{pf} - p_{r4}r_{ps} &> 0 \\ \therefore p_{r1}(r_{ps} - r_{pf}) - p_{r4}(r_{ps} - r_{pf}) + c_{p1} - c_{p2} &> 0 \\ \therefore (p_{r1} - p_{r4})(r_{ps} - r_{pf}) + c_{p1} - c_{p2} &> 0 \\ \therefore (p_{r1} - p_{r4})(r_{ps} - r_{pf} + \frac{c_{p1} - c_{p2}}{p_{r1} - p_{r4}}) &> 0 \end{aligned}$$

を満たす必要がある。つまり,

$p_{r1} > p_{r4}$  のとき,

$$\begin{aligned} r_{ps} - r_{pf} + \frac{c_{p1} - c_{p2}}{p_{r1} - p_{r4}} &> 0 \\ \therefore r_{ps} - r_{pf} &> \frac{c_{p2} - c_{p1}}{p_{r1} - p_{r4}} \end{aligned}$$

$p_{r1} < p_{r4}$  のとき,

$$\begin{aligned} r_{ps} - r_{pf} + \frac{c_{p1} - c_{p2}}{p_{r1} - p_{r4}} &< 0 \\ \therefore r_{ps} - r_{pf} &< \frac{c_{p2} - c_{p1}}{p_{r1} - p_{r4}} \end{aligned}$$

を満たせばよい。

ここで、 $E(R|s_{r2}) > \max\{E(R|s_{r1}), E(R|s_{r3}), E(R|s_{r4})\}$  が成り立つと仮定する。

このとき全ての合理的なプレイヤーは戦略  $s_{r2}$  をとり、必ず「成功」を報告するため、「評判システム」から  $p_{r1}$  と  $p_{r4}$  を推定することはできない。

ゆえに、「評判システム」の記録からは条件②を満たすような  $(r_{ps}, r_{pf})$  の組を決定できない。

以上より、条件①と条件②のいずれかを満たす  $(r_{ps}, r_{pf}, r_{rs}, r_{rf})$  の組を「評判システム」から決定することはできない。Q.E.D.

メモ：後で  $c_{p1} - c_{p2} \neq 0$  の仮定を追加？

## 第6章 倫理ある商取引ゲーム

前章では合理的なプレイヤー達による「商取引ゲーム」において、不正を防止するインセンティブ設計が不可能であることを示した。しかしながら、現実に住む我々は商取引で必ず不正に合うわけではなく、ある程度は不正が防止されている。本章では、この理論と現実の差異は限定合理性にあると考え、そうした戦略をとるプレイヤーのみで構成されたときに不正を防止することができる「倫理ある商取引ゲーム」をモデリングする。そして、そのモデルが全ての戦略をとりえるプレイヤーによって構成された「商取引ゲーム」においても、プレイヤーの構成次第で不正を防止するインセンティブ設計として機能することを示す。

### 6.1 本章における問題提起

前章では商取引ゲームにおいて必ず不正が防止できるようなインセンティブの設計が不可能であることを示した。しかしながら、現実的に私達は商取引で不正行為に遭遇することは稀である。なぜ先の理論では商取引で不正を防止するインセンティブ設計ができないにも関わらず、現実の生活の中で我々は商取引を成功させることができているのだろうか。

### 6.2 本章の仮説

不正を防止できるインセンティブ設計が可能になっているためだと思われる。限定合理性とは、認知能力の限界によって意思決定主体が限られた合理性しか持ち得ないことである。各プレイヤーにとっての最適な戦略は他のプレイヤーがとる戦略に依存しているため、当然、一部のプレイヤーが合理的に戦略を選ばないのであれば最適な戦略の均衡点も変化する。それによって、全てのプレイヤーが合理的である「商取引ゲーム」においては不可能だった相手が不正を行う可能性を推定することが可能になり、不正を防止するインセンティブ設計が可能になると予想される。

### 6.3 提案手法

このような限定合理性を「倫理」と呼び、不正行為にあった場合に必ず「失敗」を報告する行動規範とする。また、この倫理に従うプレイヤーのみによって構成される「商取引ゲーム」を「倫理ある商取引ゲーム」とする。本章では、「倫理ある商取引ゲーム」において、不正が防止されるインセンティブ設計を行い、そのインセンティブ設計を通常の「商取引ゲーム」にも適用することで、プレイヤーの構成によっては不正を防止することが可能になることを示す。

#### 6.3.1 倫理ある商取引ゲーム

「倫理ある商取引ゲーム」とは、*seller* が不正を行った場合に *buyer* がかならず「失敗」を報告する「商取引ゲーム」である。このゲームのゲーム木と非協力戦略型ゲームの利得は図 6.2 と表 6.1 のように表せる。

### 6.3.2 誠実な戦略をとった割合と成功が報告される割合の関係

「倫理ある商取引ゲーム」においては、全てのプレイヤーは「倫理」に従っているため、商取引の真の成功率は「商取引システム」に「成功」が報告された割合以上となる。つまり、任意のプレイヤー  $p$  と  $q$  が過去に「商取引ゲーム」を行った際に、誠実な戦略 ( $s_1^{seller}$  もしくは  $s_1^{buyer}$ ) をとってきた割合  $HonestStrategyRate(p, q)$  と、成功が報告された割合  $ReportedSuccessRate(p, q)$  について、次の関係が成り立つ。

$$HonestStrategyRate(p, q) \geq ReportedSuccessRate(p, q) \quad (6.1)$$

## 6.4 「倫理ある商取引ゲーム」において不正が防止される条件

### 6.4.1 不正が抑制される戦略組と期待利得の不等式

「倫理ある商取引ゲーム」において、不正を防止するためには、*seller* と *buyer* の戦略組を ( $s_1^{seller}, s_1^{buyer}$ ) に帰着させる必要がある。そのためには *seller* が戦略  $s_1^{seller}$  をとった場合の期待利得  $E(r|s_1^{seller})$  が戦略  $s_2^{seller}$  をとった場合の期待利得  $E(r|s_2^{seller})$  より大きく、*buyer* が戦略  $s_1^{buyer}$  をとった場合の期待利得  $E(r|s_1^{buyer})$  が戦略  $s_3^{buyer}$  をとった場合の期待利得  $E(r|s_3^{buyer})$  より大きくななければならない。つまり、 $E(r|s_1^{seller}) > E(r|s_2^{seller})$  かつ  $E(r|s_1^{buyer}) > E(r|s_3^{buyer})$  を満たす ( $r_{success}^{seller}, r_{failure}^{seller}, r_{success}^{buyer}, r_{failure}^{buyer}$ ) の組を「商取引システム」から決定できる必要がある。

### 6.4.2 *seller* と *buyer* の期待利得

*seller* と *buyer* の各戦略の利得の期待値は以下のように表せる。

$$E(R|s_1^{seller}) = p_1^{buyer}(r_{success}^{seller} + \epsilon^{seller}) + p_3^{buyer}(r_{failure}^{seller} + \lambda^{seller})$$

$$E(R|s_2^{seller}) = p_1^{buyer}(goods + r_{failure}^{seller} + \lambda^{seller}) + p_3^{buyer}(goods + r_{failure}^{seller} + \lambda^{seller})$$

$$= goods + r_{failure}^{seller} + \lambda^{seller}$$

$$\because p_1^{buyer} + p_3^{buyer} = 1 \text{ (「倫理ある商取引ゲーム」において、} p_2^{buyer} \text{ と } p_4^{buyer} \text{ は 0 であるため)}$$

$$E(R|s_1^{buyer}) = p_1^{seller}(goods + r_{success}^{buyer} + \epsilon^{buyer}) + p_2^{seller}(r_{failure}^{buyer} + \lambda^{buyer})$$

$$E(R|s_3^{buyer}) = p_1^{seller}(goods + r_{failure}^{buyer} + \lambda^{buyer}) + p_2^{seller}(r_{failure}^{buyer} + \lambda^{buyer})$$

$$= p_1^{seller} goods + r_{failure}^{buyer} + \lambda^{buyer}$$

$$\because p_1^{seller} + p_2^{seller} = 1$$

### 6.4.3 *seller* が誠実な戦略をとる条件

$$E(R|s_1^{seller}) > E(R|s_2^{seller})$$

$$\therefore p_1^{buyer}(r_{success}^{seller} + \epsilon) + p_2^{buyer}(r_{failure}^{seller} + \lambda) > goods + r_{failure}^{seller} + \lambda$$

$$\therefore p_1^{buyer}(r_{success}^{seller} + \epsilon) - p_1^{buyer}(r_{failure}^{seller} + \lambda) > goods$$

$$\therefore p_1^{buyer}(r_{success}^{seller} - r_{failure}^{seller} + \epsilon - \lambda) > goods$$

仮定より,  $\epsilon > \lambda$  のため,  $p_1^{buyer}(r_{success}^{seller} - r_{failure}^{seller}) \geq goods$  を満たせばよい.

$$0 < p_1^{buyer} \text{ を仮定するならば, } r_{success}^{seller} - r_{failure}^{seller} \geq \frac{goods}{p_1^{buyer}}$$

### 6.4.4 *buyer* が誠実な戦略をとる条件

$$E(R|s_1^{buyer}) > E(R|s_3^{buyer})$$

$$\therefore p_1^{seller}(goods + r_{success}^{buyer}) + p_2^{seller}r_{failure}^{buyer} > p_1^{seller}(goods + r_{failure}^{buyer}) + p_2^{seller}r_{failure}^{buyer}$$

$$\therefore p_1^{seller}(r_{success}^{buyer} - r_{failure}^{buyer}) > 0$$

$0 < p_1^{seller}$  を仮定するならば,

$$r_{success}^{buyer} - r_{failure}^{buyer} > 0$$

上記をまとめると,  $0 < p_1^{buyer}$  かつ  $0 < p_1^{seller}$  を仮定した上で,

$$r_{success}^{seller} - r_{failure}^{seller} \geq \frac{goods}{p_1^{buyer}} \text{ かつ } r_{success}^{buyer} - r_{failure}^{buyer} > 0$$

を満たせば, 「倫理ある商取引ゲーム」で不正を防止することができる.

### 6.4.5 信頼度 $p^{player}$

ここで, 任意の *player* が誠実な戦略 ( $p_1^{seller}, p_1^{buyer}$  のいずれか) をとる主観確率を  $p_1^{player}$  とすると,  $p_1^{player}$  は各プレイヤーに対して誠実な戦略をとった割合  $HonestyStrategyRate(player, opportunity)$  と任意の重み  $w^{player}$  を用いて次のように表せる.

$$p_1^{player} \equiv \sum_{opp}^{players} w^{opp} HonestyStrategyRate(player, opp) \quad (6.2)$$

### 6.4.6 最低信頼度 $T^{player}$

しかし、「商取引システム」からは  $HonestyStrategyRate(player, opportunity)$  は未知のため、信頼度  $p_1^{player}$  を求めることができない。そこで  $HonestyStrategyRate$  の代わりに  $ReportedSuccessRate$  を用い、信頼度  $p^{player}$  を計算するのと同じ重み  $w^{player}$  の荷重総和をとったものを、最低信頼度  $T^{player}$  と定義する。

$$T^{player} \equiv \sum_{opp}^{players} w^{opp} ReportedSuccessRate(player, opp) \quad (6.3)$$

### 6.4.7 最低信頼度を用いた条件

ここで  $HonestyStrategyRate \geq ReportedSuccessRate$  であるため、 $p_1^{player} \geq T^{player}$  がいえる。ゆえに、

$$r_{success}^{seller} - r_{failure}^{seller} \geq \frac{goods}{T^{buyer}} \geq \frac{goods}{p_1^{buyer}} \quad (6.4)$$

となる。

つまり、 $0 < p_1^{buyer}$  かつ  $0 < p_1^{seller}$  を仮定した上で、

$$r_{success}^{seller} - r_{failure}^{seller} \geq \frac{goods}{T^{buyer}} \text{ かつ } r_{success}^{buyer} - r_{failure}^{buyer} > 0 \quad (6.5)$$

を満たす  $(r_{success}^{seller}, r_{failure}^{seller}, r_{success}^{buyer}, r_{failure}^{buyer})$  の組を「商取引システム」から決定できれば、「倫理ある商取引ゲーム」において不正を防止することができる。

## 6.5 実験方法

先の不正が防止される条件を満たすインセンティブ設計を行う「商取引システム」と次の 8 タイプのエージェントから重複問わずランダムに選んだ 8 体のエージェントを用意し試行を実施する。これをタイプ A のエージェントが 0~7 体を占める場合について、それぞれ 8000 回づつ繰り返し、エージェントの構成と step13 で求まる「報告された成功率」と「真の成功率」を記録する。

### 6.5.1 エージェントの種類

下記の 8 タイプのエージェントを用意する。

Type A seller のとき商品を送り、buyer のときは商品を受け取った場合は「成功」、受け取らなかった場合は「失敗」を報告する。

Type B seller のとき商品を送り、buyer のときは商品を受け取った場合は「成功」、受け取らなかった場合は「成功」を報告する。



Type C seller のとき商品を送り、buyer のときは商品を受け取った場合は「失敗」、受け取らなかった場合は「成功」を報告する。

Type D seller のとき商品を送り、buyer のときは商品を受け取った場合は「失敗」、受け取らなかった場合は「失敗」を報告する。

Type E seller のとき商品を送らず、buyer のときは商品を受け取った場合は「成功」、受け取らなかった場合は「失敗」を報告する。

Type F seller のとき商品を送らず、buyer のときは商品を受け取った場合は「成功」、受け取らなかった場合は「成功」を報告する。

Type G seller のとき商品を送らず、buyer のときは商品を受け取った場合は「失敗」、受け取らなかった場合は「成功」を報告する。

Type H seller のとき商品を送らず、buyer のときは商品を受け取った場合は「失敗」、受け取らなかった場合は「失敗」を報告する。

### 6.5.2 試行

step 1 時刻  $t$  を 0 とする。

step 2 「商取引システム」の各エージェントの通貨保有量を 8 とする。

step 3 各プレイヤーが互いに seller と buyer のそれぞれの役割で 1 度ずつ商取引ゲームを行う順序を決定する。(順序の長さは 56 となる)

step 4 時刻  $t$  を 1 進める。

step 5 step 3 で決定した順序を周期として、seller と buyer を決定する。

step 6 「商取引システム」はこれまで報告された結果から、「成功」と「失敗」が報告された場合の seller と buyer の通貨保有量を計算する。

step 7 seller は自身の戦略に基づいて、buyer に商品を送るか、もしくは商品を送らない。

step 8 buyer は自身の戦略と step 6 の seller の行動に基づいて、「商取引ゲーム」の結果を決定する。

step 9 buyer は決定した結果を「商取引システム」に報告する。

step 10 「商取引システム」は step 6 で計算した通貨保有量がいずれの場合にも 0 未満にならない場合、buyer から報告された結果を記録する。

step 11 step 6 で計算した通貨保有量がいずれの場合にも 0 未満にならない場合、真の結果を記録する。

step 12 時刻  $t$  が 1120 未満なら、step 4 に戻る。

step 13 過去 56 回の商取引ゲームにおいて、step 10 と 11 で記録された結果を集計し、それぞれ「報告された成功率」と「真の成功率」を求める。

## 6.6 「商取引システム」の詳細

本節ではシミュレーションを実装するにあたって必要となる商取引システムの仕様の詳細の一部を紹介する。完全な実装については、GitHub のソースコードを参照。

### 6.6.1 ReputationWeight

最低信頼度  $T^{player}$  を求めるためには、 $ReportedSuccessRate(p, q)$  に係る任意の重み  $w^{player}$  を決定する必要がある。この重み  $w^{player}$  は、任意の  $player$  が誠実な戦略をであろう主観確率を考える際にその  $player$  と取引相手  $opportunity$  との間での報告された成功率  $ReportedSuccessRate(player, opportunity)$  をどの程度信頼するかを表している。本論では、保有している通貨の全体に占める割合を  $ReputationWeight w^{player}$  任意の  $player$  の通貨保有量を  $b^{player}$  としたとき、

$$w^{player} \equiv \frac{b^{player}}{\sum_i^{players} b^i}$$

### 6.6.2 「成功」が報告された場合の通貨保有量の変化

「商取引ゲーム」において、 $buyer$  から成功が報告された場合、 $buyer$  は商品  $goods$  の価格  $price$  だけ通貨保有量が減り、 $seller$  は  $price$  だけ通貨保有量が増えるものとする。

そのため商取引前後では  $seller$  と  $buyer$  の残高の合計は変化しない。ここから、 $r_{success}^{seller}$  と  $r_{success}^{buyer}$  は以下のように記せる。

$$\begin{aligned} r_{success}^{seller} &= price \\ r_{success}^{buyer} &= -price \\ r_{success}^{seller} + r_{success}^{buyer} &= 0 \end{aligned}$$

### 6.6.3 EscrowCost

まずは「失敗」が報告された時に  $seller$  と  $buyer$  から失われる通貨の量の合計を  $EscrowCost$  とおいて考え、同時に商品価格  $price$  にエスクロー係数  $E$  を掛けたものとする。（ここで  $price$  は  $goods$  の価格である）

$$\begin{aligned} EscrowCost &\equiv (r_{success}^{buyer} - r_{failure}^{buyer}) + (r_{success}^{seller} - r_{failure}^{seller}) \\ &= E \cdot price \end{aligned} \tag{6.6}$$

### 6.6.4 EscrowCost の負担比率

$EscrowCost$  の負担比率は  $seller$  と  $buyer$  の最低信頼度  $T^{player}$  を用いる。

$$(r_{success}^{buyer} - r_{failure}^{buyer}) : (r_{success}^{seller} - r_{failure}^{seller}) = T^{buyer} : T^{seller} \tag{6.7}$$

### 6.6.5 EscrowCost の分配

「失敗」が報告されたときに *EscrowCost* が消失すると、全体の通貨量が減少して通貨の価値が上がり商品価格が下がる。商品価格の変動を防ぐために本実験では *seller* と *buyer* 以外の全てのプレイヤーに、そのプレイヤーの通貨保有量に応じて *EscrowCost* を分配する。*seller* と *buyer* を含まないのは、分配によって「商取引ゲーム」のインセンティブ設計が変化しないようにするためである。

## 6.7 評価

先の実験の結果、「報告された成功率」と「真の成功率」の両方が 100%になった場合を「不正防止の成功」とし、誠実なエージェント (タイプ A) の数と「不正防止の成功」に至った割合をプロットしたものが、図 6.1 である。(エージェント数 8 の場合は、エージェントの組み合わせが 1 通りしか存在しないため、個別に試行を行い結果を集計している。) 誠実なエージェントの数が 0 体の場合であっても不正が防止される構成が存在し、6 体以上の場合はサンプリングした全ての構成で不正の防止が成功していた。

## 6.8 結論

実験とその評価を踏まえて、「倫理」という限定合理性を仮定した上でインセンティブ設計を行うことで、プレイヤーの構成によっては「商取引ゲーム」において不正を防止することが可能であることがわかる。また、プレイヤーの構成と不正防止の成功成功の関係性については、先の実験の図のとおりである。




図 6.1: 誠実なエージェントの数と「不正防止の成功」に至った割合

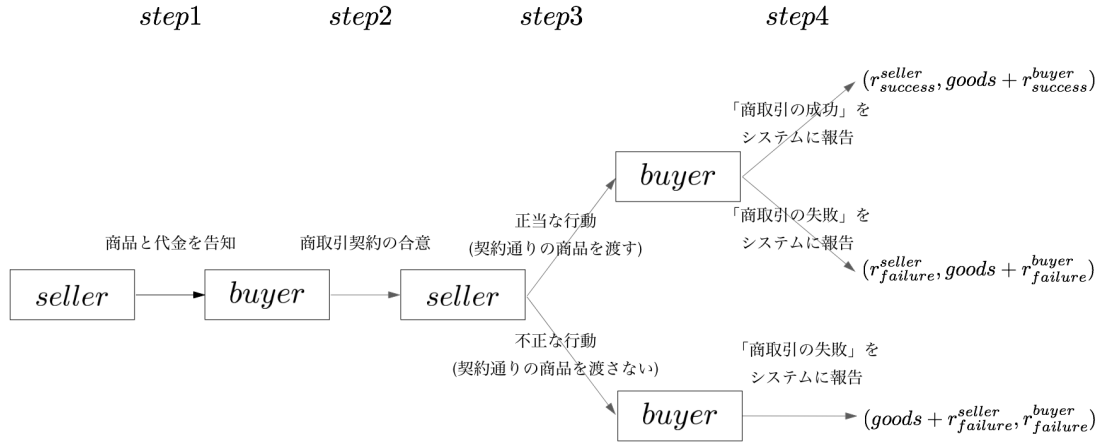


図 6.2: 「倫理ある商取引ゲーム」のゲーム木

|               |                | <i>buyer</i>  |   |
|---------------|----------------|---|---|
|               |                | $s_1^{buyer}$   | $s_3^{buyer}$   |
| <i>seller</i> | $s_1^{seller}$ | $(r_{success}^{seller}, goods + r_{success}^{buyer})$ | $(r_{failure}^{seller}, goods + r_{failure}^{buyer})$ |
|               | $s_2^{seller}$ | $(goods + r_{failure}^{seller}, r_{failure}^{buyer})$ | $(goods + r_{failure}^{seller}, r_{failure}^{buyer})$ |

表 6.1: 非協力戦略型ゲームとして表した「倫理ある商取引ゲーム」の利得表

### 6.8.1 非協力戦略型ゲーム

## 第7章 複雑系としての社会契約

「倫理ある商取引ゲーム」において、倫理という限定合理性を仮定した上で商取引システムのインセンティブ設計を行えば、プレイヤーの構成によっては不正が防止され、商取引契約の内容が果たされるようになることがわかった。本章では、この商取引契約の内容に焦点を当て、これまで外部の強制執行力として存在が仮定されていた「商取引システム」を、ある集団の成員が構成する複雑系の内部で自己組織化されたシステムとして再現する商取引契約の内容について提案し、マルチエージェントシミュレーションによって、商取引システムが存在しない場合でも、社会契約が成立しうることを示す。

### 7.1 本章の問題提起

本章では先の章で扱った「倫理ある商取引ゲーム」において、外部の強制執行力として存在が仮定されていた「商取引システム」が存在しない場合でも、プレイヤーの構成によって「商取引ゲーム」の不正を防止することが可能であるかという問いに取り組む。

### 7.2 本章の仮説

商取引システムが存在する場合に、商取引契約を履行させることが可能であるとする。このとき、各プレイヤーが商取引システムと同様の役割を演じることができれば、外部の強制執行力としての商取引システムが存在せずとも相互監視の元で商取引ゲームで不正を防止し続けることが可能となるだろう。

### 7.3 提案手法

先の仮説を検証するためには、各プレイヤーが商取引システムの役割を正しく演じる商取引契約の内容を記述し、その商取引契約の履行を約束する「商取引ゲーム」を繰り返した結果、全てのプレイヤーが「商取引ゲーム」で不正を行えない状態になりうることを示す必要がある。

ここで、「商取引システム」とはどういったシステムであったかに立ち返ると、「商取引システム」とは、各プレイヤーの初期の通貨保有量と保存された各時刻の商取引の記録から、各プレイヤーの通貨保有量を一意に決定するシステムである。それ故、初期の通貨保有量と保存された各時刻の商取引の記録が全てのプレイヤーで一致しているとき、全てのプレイヤーが商取引システムが正しく動作しているといえる。

それを実現するためには、各プレイヤーが保存している過去の商取引の記録を互いに確認し合い、差異が生じた場合に全てのプレイヤーに「失敗」を報告する商取引契約の内容を記述すればよい。

そこで、本章では下記のような「成員の振る舞い」を提案し、先の仮説が成り立つことを検証する。

#### 7.3.1 成員の振る舞い

- 事前の合意に基づいた全てのプレイヤーの人数  $n$  と各プレイヤーの初期の通貨保有量  $b_1, \dots, b_n$  を定義する。

- 事前の合意に基づいた各プレイヤーが他の全てのプレイヤーと *seller* と *buyer* のそれぞれの役割で 1 度づつ「商取引ゲーム」を行う周期を定義する。(周期の長さは  $n * (n - 1)$ )
- 事前の合意に基づいた仕様に従った商取引システムを用意する。
- 事前の合意に基づいた商取引契約の内容を定義する。
- 時刻  $t$  において、「時刻  $t$  における成員の振る舞い」を上から順に実行する。
- 商取引の記録とは、商取引が行われた時刻  $t$  と *seller*、*buyer*、結果、報告者からなる記録とする。

### 7.3.2 時刻 $t$ における成員の振る舞い

**step 1** 現在時刻の *seller* と *buyer* を決定する。

**step 2** 自身が *seller* ならば、時刻  $\max\{0, t - n * (n - 1)\}$  から時刻  $t$  までの各時刻  $k$  について、保管されている商取引の記録のうち、時刻が  $k$  で報告者がその商取引の記録の *buyer* と一致するものを全て集め複製する。その複製された全ての商取引の記録に署名して *buyer* に送信する。

**step 3** 自身が *buyer* ならば、*seller* から受け取った記録の署名を検証し、添付された全ての商取引の記録の報告者を *seller* に書き換えて保管する。*seller* からメッセージを受け取っていない場合、この step では何もしない。

**step 4** 自身が *buyer* ならば、時刻  $\max\{0, t - 2 * n * (n - 1)\}$  から時刻  $\max\{0, t - n * (n - 1)\}$  までの各時刻  $k$  について、保管されている商取引の記録のうち、時刻が  $k$  のものを集め、それらの結果が全て一致しているかを確認する。もし一致している場合、その一致した結果を商取引システムに報告された結果として入力する。一致しない場合、またはその時刻の商取引の記録が存在しない場合、報告された結果として自身の商取引システムに「失敗」を入力する。

**step 5** 自身が *buyer* ならば、商取引契約の結果を決定する。

**step 6** step5 で決定した結果をもとに商取引の記録を作成し、署名して、全てのプレイヤーに送信する。

**step 7** *buyer* から報告された商取引の記録を保管する。この際、記録の報告者は *buyer* とする。*buyer* から報告を受け取っていない場合、この step では何もしない。

## 7.4 実験方法

ここでは「時刻  $t$  における成員の振る舞い」の step 6 が必ず遵守される状態を作り出せるかを確認するため、下記の「実験用の商取引契約」を合意された商取引契約として、これを履行する場合と履行しない場合で 4 種づつ、計 8 タイプのエージェントを用意する。この 8 タイプのエージェントから重複問わずランダムに選んだ 8 体のエージェントを用意し試行を実施する。これをタイプ A のエージェントが 0~7 体を占める場合について、それぞれ 8000 回づつ繰り返し、エージェントの構成と step9 で求まる「報告された成功率」と「真の成功率」を記録する。

### 7.4.1 実験用の商取引契約

*seller* が「成員の振る舞い」の step6 の通りに振る舞う対価として、*buyer* が通貨を 1 支払う商取引契約を結ぶ。*buyer* は *seller* がこの商取引を履行したかどうかを「step6 の検証」によって確認することができる。

### 7.4.2 step6 の検証

時刻  $t$  において、*buyer* は *seller* が「成員の振る舞い」の step6 を履行したかを下記の 2 つの検証で確かめることができる。検証 1 は全てのプレイヤーに同じ商取引の結果を送信したことを検証する方法であり、検証 2 は *buyer* に商取引の結果を送信したかを検証する方法である。

**検証 1** 時刻  $\max\{0, t - 2 * n * (n - 1)\}$  から時刻  $\max\{0, t - n * (n - 1)\}$  までのうち、その時刻に行われた商取引の *buyer* が現在時刻の商取引の *seller* である各時刻  $k$  について、保管されている商取引の記録のうち、時刻が  $k$  のものを集め、その中に報告者が時刻  $t$  の商取引の *seller* が存在し、それらの結果が一致していることを確認する。

**検証 2** 時刻  $\max\{0, t - 2 * n * (n - 1)\}$  から時刻  $\max\{0, t - n * (n - 1)\}$  までのうち、その時刻に行われた商取引の *buyer* が現在時刻の商取引の *seller* である各時刻について、保管されている商取引の記録のうち、その時刻の商取引の記録を集めて、その中に報告者が現在時刻の商取引の *seller* である記録が存在するかを確認する。

### 7.4.3 エージェントの種類

下記の 8 タイプのエージェントを用意する。下記に記述のない振る舞いに関しては「成員の振る舞い」に従う。

- A 完全に商取引契約を履行するエージェント
- B step5 を無視して必ず「成功」を報告するエージェント
- C step5 と逆の結果を報告するエージェント
- D step5 を無視して必ず「失敗」を報告するエージェント
- E step6 でタイプ A にだけ結果を送らないエージェント
- F step6 でタイプ A にだけ結果を送らず、step5 を無視して必ず「成功」を報告するエージェント
- G step6 でタイプ A にだけ結果を送らず、step5 と逆の結果を報告するエージェント
- H step6 でタイプ A にだけ結果を送らず、step5 を無視して必ず「失敗」を報告するエージェント

### 7.4.4 試行

**step 1** 時刻  $t$  を 0 とする。

**step 2** 各プレイヤーが互いに *seller* と *buyer* のそれぞれの役割で 1 度ずつ商取引ゲームを行う順序を決定し、各エージェントが合意する。(順序の長さは 56 となる)

**step 3** プレイヤー数は 8、初期の通貨保有量は各プレイヤー 8、商取引システムの仕様は前章の実験と同じものとし、各エージェントが合意する。

**step 4** 時刻  $t$  を 1 進める。

**step 5** 各エージェントはその特性に則って振る舞う。



**step 6** 各エージェントの「商取引システム」において、時刻  $t$  の入力によって誰の通貨保有量も 0 未満にならない場合、報告された結果を記録する。

**step 7** 各エージェントの「商取引システム」において、時刻  $t$  の入力によって誰の通貨保有量も 0 未満にならない場合、真の結果を記録する。

**step 8** 時刻  $t$  が 1120 未満なら、step4 に戻る。

**step 9** 各エージェントの「商取引システム」において、過去 56 回分の step5 と 6 で記録された結果を集計し、それぞれ「報告された成功率」と「真の成功率」を求める。

## 7.5 評価

サンプリングした結果を元に、タイプ A のエージェントと自己組織化が成功した割合をプロットすると、図 7.1 のようになる。この図から、誠実なプレイヤーが 6 人以上の場合は全てのサンプルで自己組織化に成功していることがわかる。




図 7.1: 誠実なエージェントの数と自己組織化に成功した割合

## 第8章 結論

### 8.1 本論のまとめ

### 8.2 本論の課題

### 8.3 今後の研究

## 謝辭

## 参考文献

- [1] Bruno Verbeek and Christopher Morris. Game Theory and Ethics. In Edward N. Zalta, editor, *The Stanford Encyclopedia of Philosophy*. Metaphysics Research Lab, Stanford University, Winter 2020 edition, 2020.
- [2] GSMA.
- [3] Google.
- [4] Facebook.
- [5] Satoshi Nakamoto. Bitcoin: A peer-to-peer electronic cash system. 2008.
- [6] Kenji Saito and Shugo Ikemoto. 地球規模 os 外殻 (シエル) の開発と応用. 2008.
- [7] Ken Binmore. *Natural Justice*. New York: Oxford University Press, 2005.
- [8] Jean-Jacques Rousseau. *Discourse on the Origin of Inequality*. 1755.
- [9] Brian Skyrms. The stag hunt. In *Proceedings and Addresses of the American Philosophical Association*, volume 75, pages 31–41. JSTOR, 2001.
- [10] Ullmann-Margalit Edna. The emergence of norms, 1977.
- [11] John Mackie. *Ethics*. Penguin Books Ltd, 1977.
- [12] John C Harsanyi. Cardinal welfare, individualistic ethics, and interpersonal comparisons of utility. *Journal of Political Economy*, 63(4):309–321, 1955.
- [13] John Rawls. *A Theory of Justice*. Cambridge: Harvard University Press, 1971.
- [14] Robert Sugden. *The Economics of Rights, Co-operation and Welfare*. Oxford: Basil Blackwell, 1986.
- [15] Ken Binmore. *Playing Fair (Game Theory and the Social Contract; vol 1)*. Cambridge: The MIT Press, 1994.
- [16] Ken Binmore. *Just Playing (Game Theory and the Social Contract, vol. 2)*. Cambridge: The MIT Press, 1998.
- [17] Brian Skyrms. *Evolution of the social contract*. Cambridge University Press, 1996.
- [18] Herbert A Simon. *Administrative behavior; a study of decision-making processes in administrative organization*. 1947.
- [19] Gregory Wheeler. Bounded Rationality. In Edward N. Zalta, editor, *The Stanford Encyclopedia of Philosophy*. Metaphysics Research Lab, Stanford University, Fall 2020 edition, 2020.

- [20] Werner Güth, Rolf Schmittberger, and Bernd Schwarze. An experimental analysis of ultimatum bargaining. *Journal of Economic Behavior & Organization*, 3(4):367–388, 1982.
- [21] LESLIE LAMPORT, ROBERT SHOSTAK, and MARSHALL PEASE. The byzantine generals problem. *ACM Transactions on Programming Languages and Systems*, 4(3):382–401, 1982.